

Gestión, Metodologías ágiles y Capstone

Semana 1

Definiciones Claves, Gobierno de Datos y Liderazgo Analítico en Entornos Estocásticos

MÓDULO 1

Fundamentos de Gestión Analítica

Conceptos epistemológicos de la gestión, valor de la información y teorización sistémica en la ciencia de datos aplicada.

Definición Formal de Gestión

Gestión Operativa e Ingeniería

Coordinación sistémica de recursos humanos, tecnológicos, financieros y metodológicos para transformar insumos heterogéneos en valor estratégico sustentable, bajo restricciones deterministas y estocásticas de proyecto.

Dimensión Analítica y Estadística

Aplicación rigurosa de principios de optimización, gobernanza de metadatos y control estadístico de calidad sobre el ciclo de vida de la información para minimizar el riesgo y la variabilidad en la toma de decisiones.

Jerarquía DIKW en Ingeniería

-  **Datos (Data):** Observaciones crudas no estructuradas o estructuradas descritas formalmente por un espacio muestral sin contexto semántico predefinido.
-  **Información (Information):** Datos procesados, estructurados y contextualizados probabilísticamente según una distribución que otorga significado operativo.
-  **Conocimiento (Knowledge):** Inferencia estadística probada, patrones parametrizados y modelos predictivos/causales validados empíricamente que permiten generalización.
-  **Sabiduría (Wisdom):** Optimización de decisiones estratégicas organizacionales reduciendo la pérdida esperada bajo riesgo e incertidumbre epistémica.

MÓDULO 2

Gobierno de Datos e Información

Ciclo de vida institucional de la información, marcos normativos, calidad de datos e infraestructura de soporte analítico.

Marcos de Gestión Analítica

Marco / Estándar	Foco Principal	Gestión de Incertidumbre	Entregable Clave
CRISP-DM	Ciclo de Minería de Datos	Iterativa (Fase a Fase)	Modelo Desplegado / Reporte Inferencia
TDSP (Microsoft)	Proyectos de Ciencia de Datos	Estructura de Repositorio y CI/CD	Pipelines MLOps / Artifacts
DAMA-DMBOK2	Gobierno e Infraestructura de Datos	Control de Calidad y Metadatos	Data Governance Framework
PMBOK v7 / PRINCE2	Gestión Organizacional de Proyectos	Matriz de Riesgos Generales	Business Case / Acta de Constitución


DAMA-DMBOK2 y Calidad de Datos

 **Arquitectura y Linaje:** Trazabilidad completa desde la ingesta en OLTP/Data Lake hasta el consumo en el Feature Store.

✓ **Dimensiones de Calidad:** Exactitud, completitud, consistencia temporal, validez de dominio y unicidad sin duplicaciones.

 **Metadatos Estadísticos:** Documentación estandarizada de diccionarios de variables, distribuciones de referencia y esquemas de codificación.

 **Seguridad y Privacidad:** Anonimización, encriptación en tránsito y reposo, e historias de acceso auditables.



Deuda Técnica y Variabilidad


Deuda Técnica Analítica

Acumulación de atajos en la limpieza de datos, código monolítico sin pruebas unitarias de datos, ausencia de automatización en retrenado y falta de documentación de hiperparámetros que encarecen el mantenimiento futuro del sistema.

Variabilidad Estocástica vs Epistémica

La variabilidad aleatoria es inherente al fenómeno aleatorio investigado (), mientras que el riesgo epistémico deriva de la falta de conocimiento, tamaño de muestra insuficiente o sesgo de diseño del proyecto.

Distribución del Esfuerzo en Proyectos



Aproximadamente el 65% del esfuerzo de gestión técnica se concentra en la preparación e ingeniería de variables, desmontando el mito de que el entrenamiento estadístico constituye el volumen principal de trabajo en producción.

MÓDULO 3

Roles y Responsabilidades

Estructura organizacional, perfiles analíticos especializados y liderazgo técnico en equipos multidisciplinarios.

Matriz RACI en Proyectos Analíticos

Actividad del Proyecto	Data Project Lead	Lead Statistician	Data Engineer	MLOps Engineer
Definición del Alcance y Negocio	A / R	C	I	I
Diseño de Pipelines e Ingesta	A	C	R	C
Selección y Validación del Modelo	A	R	C	C
Despliegue y Monitoreo de Drift	A	C	C	R

Perfil del Data Project Lead

Traducción Estratégica

Capacidad de conectar los requerimientos cualitativos de negocio con hipótesis estadísticas formalizadas. Traduce métricas de rendimiento estadístico (AUC, Log-Loss, p-valores) en impacto financiero directo (ROI, reducción de churn, eficiencia de costos).

Gestión de Riesgo Analítico

Identificación temprana de cuellos de botella en la calidad de datos, sesgos muestrales y fallas de infraestructura. Lidera la comunicación técnica con stakeholders no analíticos y asegura la entrega bajo el cronograma acordado.

Rol del Estadístico Líder



Validación de Supuestos Teóricos: Verificación rigurosa de homocedasticidad, no-multicolinealidad, normalidad de errores e independencia.



Diseño de Experimentos (DoE): Determinación matemática del tamaño muestral, potencia del test () y control de variables de confusión.



Prevención de Sobreajuste (Overfitting): Definición de esquemas de validación cruzada estratificada por bloques temporales o grupos no balanceados.




Auditoría de Inferencia: Control del error tipo I en comparaciones múltiples y mitigación explícita de prácticas de *p-hacking* o *data dredging*.

MÓDULO 4

Gobernanza y Regulación

Degradación temporal de modelos, regulaciones éticas, protección de datos personales e interpretabilidad algorítmica.

Concept Drift y Degradación Temporal



Medida de métrica de desempeño (F1-Score / AUC) a lo largo del tiempo sin gobernanza activa. El cambio en la distribución generadora de datos $p_t(y|x) \neq p_{t+1}(y|x)$ degrada irremediablemente el valor predictivo sin retrenado continuo.

Métrica de Fracaso Analítico

85%

Proyectos Sin Producción

Causas Organizacionales Técnicas

Estudios de la industria (Gartner/McKinsey) revelan que el 85% de los modelos estadísticos y analíticos desarrollados no logran ser integrados operativamente.

La falla no radica en la complejidad matemática del algoritmo, sino en la ausencia de una gestión adecuada del ciclo de vida, falta de gobernanza de datos y desacople entre ingenieros de datos y tomadores de decisiones.

Gobernanza Ética y Legal

Marco Regulatorio (GDPR / Ley 1581)

Garantía explícita de Habeas Data, derecho a la explicación en decisiones automatizadas, técnicas de anonimización irreversibles y cumplimiento estricto de privacidad diferencial ().

Explicabilidad e Interpretabilidad

Implementación de métodos agnósticos al modelo (SHAP - Shapley Additive Explanations, LIME) para auditar la importancia local y global de covariables en dominios de alto riesgo como crédito y salud.

Fases del Pipeline Analítico

2. Feature Store

Transformación
determinista,
escalamiento e
ingeniería de variables
reutilizables.

4. MLOps y API

Empaquetamiento en
contenedores,
integración continua y
monitoreo de drift.

1. Ingesta y EDA

Problematización
formal, muestreo inicial
y verificación de calidad
de datos DAMA.

3. Modelado y DoE


Ajuste de
hiperparámetros,
estimación de
coeficientes e
inferencia
probabilística.

MÓDULO 5

Gestión Estocástica de Proyectos

Adaptación del marco de triple restricción, costo de calidad y cuadro de mando integral analítico.

Composición de Costos de Calidad



Invertir proactivamente en prevención y validación de esquemas reduce drásticamente el costo financiero y reputacional de fallas críticas en producción.

Cuadro de Mando de Proyectos

🎯 **Métrica de Impacto Negocio:** Incremento en margen operativo (\$) o reducción de tasa de deserción de clientes.

📊 **Métrica de Estabilidad Estadística:** Invariancia en test de Kolmogorov-Smirnov () para distribuciones de entrada.
D

🕒 **Métrica de Desempeño Técnico:** Latencia p99 de inferencia en API (< 50ms) y porcentaje de cobertura de pruebas unitarias.

📄 **Métrica de Gobierno:** Cumplimiento del 100% en documentación de metadatos según estándar DAMA.

Triple Restricción Analítica

Paradigma Tradicional (Fijo)

En ingeniería clásica, el Alcance, Tiempo y Costo se fijan desde el inicio en una matriz determinista rígida (Diagrama de Gantt clásico).

Paradigma Analítico (Estocástico)


En ingeniería estadística, la **Calidad de Inferencia y la Explicabilidad** se fijan como intransigibles, mientras el Alcance se flexibiliza iterativamente según la viabilidad muestral hallada en el análisis exploratorio.

MLOps e Infraestructura

Infraestructura de Producción

La gestión profesional de proyectos analíticos requiere trascender los entornos locales (Jupyter Notebooks) hacia plataformas empresariales MLOps integradas.

La adopción de orquestadores de flujos (Airflow/Prefect), control de versiones de datos (DVC) y empaquetamiento estandarizado (Docker/Kubernetes) garantiza reproducibilidad e industrialización sólida.



Filosofía de Modelado y Gestión

“Todos los modelos son falsos, pero algunos son útiles.”

— George E. P. Box (Estadístico Británico)

”

Gestión Determinista vs Estocástica

Dimensión	Gestión de Software Tradicional	Gestión de Proyectos Estadísticos
Naturaleza de la Lógica	Determinista (Reglas de código explícitas)	Probabilística (Basada en distribuciones de datos)
Validación	Pruebas de Software (Pass/Fail)	Validación de Inferencia y Métricas de Error
Mantenimiento	Corrección de Bugs / Refactorización	Retrenado de Modelos por Drift de Datos
Incertidumbre	Baja (Requerimientos funcionales)	Alta (Incertidumbre epistémica y aleatoria)

Gestión de Reproducibilidad

Reproducibilidad Técnica

Fijación rigurosa de semillas aleatorias (), congelamiento de versiones de librerías en ambientes virtuales y aislamiento de contenedores para asegurar idénticos resultados computacionales.

Inferencia Causal Operativa

Diferenciación estricta entre la correlación observacional observada y el efecto causal real bajo intervención para evitar decisiones de gestión erróneas por variables de confusión.

Síntesis y Hoja de Ruta



La gestión en ingeniería estadística trasciende la administración clásica al incorporar el rigor estocástico en el control de proyectos.



El Data Project Lead opera como puente crítico entre las hipótesis probabilísticas y el valor estratégico de negocio.



El gobierno de datos (DAMA-DMBOK) y la arquitectura MLOps son habilitadores clave para prevenir la tasa de fracaso del 85%.



Próxima Sesión (Semana 2): Metodologías Ágiles (Scrum/Kanban) aplicadas a la naturaleza iterativa de la ciencia de datos.

¿Preguntas y Debate?

Espacio para la discusión teórica y alineación conceptual con los proyectos Capstone GMAC.

Escuela Colombiana de Ingeniería Julio Garavito | Unidad de Proyectos – GMAC